

Universidade de Brasília – UnB

Faculdade de Ciências e Tecnologias em Engenharia – FCTE

Engenharia de Software

Contexto de negócio e confiabilidade de LLMs na análise de dados empresariais: avaliação de um assistente text-to-SQL para usuários não técnicos

Autor: Caio Lucas Lelis Borges

Orientador: Prof. Dr. Fabiano Araujo Soares

Brasília, DF

2026



Caio Lucas Lelis Borges

Contexto de negócio e confiabilidade de LLMs na análise de dados empresariais: avaliação de um assistente text-to-SQL para usuários não técnicos

Monografia submetida ao curso de graduação em Engenharia de Software da Universidade de Brasília, como requisito parcial para obtenção do Título de Bacharel em Engenharia de Software.

Universidade de Brasília – UnB

Faculdade de Ciências e Tecnologias em Engenharia – FCTE

Orientador: Prof. Dr. Fabiano Araujo Soares

Brasília, DF

2026

Caio Lucas Lelis Borges

Contexto de negócio e confiabilidade de LLMs na análise de dados empresariais: avaliação de um assistente text-to-SQL para usuários não técnicos/ Caio Lucas Lelis Borges. – Brasília, DF, 2026-

61 p. : il. (algumas color.) ; 30 cm.

Orientador: Prof. Dr. Fabiano Araujo Soares

Trabalho de Conclusão de Curso – Universidade de Brasília – UnB
Faculdade de Ciências e Tecnologias em Engenharia – FCTE , 2026.

1. Text-to-SQL. 2. Modelos de linguagem. I. Prof. Dr. Fabiano Araujo Soares. II. Universidade de Brasília. III. Faculdade de Ciências e Tecnologias em Engenharia. IV. Contexto de negócio e confiabilidade de LLMs na análise de dados empresariais: avaliação de um assistente text-to-SQL para usuários não técnicos

CDU 02:141:005.6

Caio Lucas Lelis Borges

Contexto de negócio e confiabilidade de LLMs na análise de dados empresariais: avaliação de um assistente text-to-SQL para usuários não técnicos

Monografia submetida ao curso de graduação em Engenharia de Software da Universidade de Brasília, como requisito parcial para obtenção do Título de Bacharel em Engenharia de Software.

Trabalho aprovado. Brasília, DF, 01 de junho de 2013 – Data da aprovação do trabalho:

Prof. Dr. Fabiano Araujo Soares
Orientador

Titulação e Nome do Professor
Convidado 01
Convidado 1

Titulação e Nome do Professor
Convidado 02
Convidado 2

Brasília, DF
2026

A dedicatória é opcional. Caso não deseje uma, deixar todo este arquivo em branco.

Este trabalho é dedicado às crianças adultas que,
quando pequenas, sonharam em se tornar cientistas.

Agradecimentos

A inclusão desta seção de agradecimentos é opcional, portanto, sua inclusão fica a critério do(s) autor(es), que caso deseje(em) fazê-lo deverá(ão) utilizar este espaço, seguindo a formatação de *espaço simples e fonte padrão do texto (sem negritos, aspas ou itálico.*

Caso não deseje utilizar os agradecimentos, deixar toda este arquivo em branco.

A epígrafe é opcional. Caso não deseje uma, deixe todo este arquivo em branco.

"Não vos amoldeis às estruturas deste mundo,
mas transformai-vos pela renovação da mente,
a fim de distinguir qual é a vontade de Deus:
o que é bom, o que Lhe é agradável, o que é perfeito.
(Bíblia Sagrada, Romanos 12, 2)

Resumo

Modelos de linguagem de grande escala permitem que usuários não técnicos consultem bancos de dados empresariais em linguagem natural, por meio da tradução de perguntas em consultas SQL (*text-to-SQL*). Em bases reais, porém, o significado das métricas depende de regras de negócio que não constam do esquema das tabelas, e o modelo pode gerar consultas válidas que retornam resultados incorretos sem qualquer sinal de erro. Este trabalho propõe avaliar em que medida o nível de contexto de negócio fornecido ao modelo afeta a acurácia das respostas e a autonomia de usuários não técnicos na análise de dados do domínio comercial. Para isso, será desenvolvido um assistente no qual o usuário anexa as tabelas em arquivos CSV, descreve cada uma delas e registra as regras de negócio, recebendo as respostas na forma de texto interpretativo, gráfico interativo e tabela. O contexto será manipulado em três configurações: esquema puro, esquema documentado e camada semântica. Um banco de 20 perguntas com gabarito, validado por analistas de negócio, será executado nas três configurações com um único modelo, e a acurácia de execução será comparada por testes estatísticos pareados, com classificação dos erros encontrados. Em seguida, de 5 a 8 usuários não técnicos realizarão tarefas na configuração de melhor desempenho, com medição da taxa de acerto, do tempo e da usabilidade pela escala SUS. Espera-se quantificar o ganho de acurácia proporcionado pelo contexto de negócio e indicar se, nessa condição, usuários não técnicos obtêm respostas corretas sem o apoio de analistas.

Palavras-chave: Text-to-SQL. Modelos de linguagem de grande escala. Contexto de negócio. Análise de dados. Usabilidade.

Abstract

Large language models allow non-technical users to query enterprise databases in natural language by translating questions into SQL queries (text-to-SQL). In real databases, however, the meaning of metrics depends on business rules that are not present in the table schema, and the model may generate valid queries that return incorrect results without any sign of error. This work proposes to assess to what extent the level of business context provided to the model affects the accuracy of the answers and the autonomy of non-technical users in data analysis in the sales domain. To this end, an assistant will be developed in which the user uploads tables as CSV files, describes each of them and records the business rules, receiving answers as interpretive text, an interactive chart and a table. The context will be manipulated in three configurations: plain schema, documented schema and semantic layer. A set of 20 questions with reference answers, validated by business analysts, will be run in all three configurations with a single model, and execution accuracy will be compared using paired statistical tests, with a classification of the errors found. Next, 5 to 8 non-technical users will perform tasks in the best-performing configuration, with measurement of task success rate, time and usability through the SUS scale. The work is expected to quantify the accuracy gain provided by business context and to indicate whether, under this condition, non-technical users obtain correct answers without support from analysts.

Key-words: Text-to-SQL. Large language models. Business context. Data analysis. Usability.

Lista de ilustrações

Figura 1 – Consulta válida com resultado incorreto por falta de contexto 31
Figura 2 – Arquitetura do assistente 37
Figura 3 – Fluxo de uma pergunta no assistente 39
Figura 4 – Contexto de uma tabela nas configurações C0, C1 e C2 41

Lista de tabelas

Tabela 1 – Comparação entre os conjuntos de avaliação Spider e BIRD 29
Tabela 2 – Dimensões de usabilidade e métricas correspondentes no estudo com usuários 32
Tabela 3 – Comparação entre os trabalhos relevantes e este trabalho 33
Tabela 4 – Conceitos do referencial teórico e seu uso no trabalho 34
Tabela 5 – Requisitos funcionais e não funcionais do assistente 36
Tabela 6 – Configurações de contexto de negócio 40
Tabela 7 – Campos de cada item do banco de perguntas 43
Tabela 8 – Etapas do trabalho 46
Tabela 9 – Perguntas e métricas derivadas do objetivo de medição 46
Tabela 10 – Ameaças à validade e mitigações 51
Tabela 11 – Esforço estimado por parte do desenvolvimento 52
Tabela 12 – Esforço estimado das atividades de pesquisa e escrita 52
Tabela 13 – Sequência das atividades do TCC2 em semanas relativas 53
Tabela 14 – Encaminhamento dos objetivos específicos no TCC2 56
Tabela 15 – Riscos de execução e mitigações 56

Lista de abreviaturas e siglas

API	*Application Programming Interface*
BI	*Business Intelligence*
CSV	*Comma-Separated Values*
GQM	*Goal Question Metric*
ISO	*International Organization for Standardization*
JSON	*JavaScript Object Notation*
LGPD	Lei Geral de Proteção de Dados Pessoais
LLM	*Large Language Model*
RF	Requisito Funcional
RNF	Requisito Não Funcional
SQL	*Structured Query Language*
SUS	*System Usability Scale*
TCLE	Termo de Consentimento Livre e Esclarecido

Sumário

1 INTRODUÇÃO . . . 23
1.1 Contextualização . . . 23
1.2 Justificativa . . . 23
1.3 Problema de pesquisa . . . 24
1.4 Objetivos . . . 24
1.4.1 Objetivo geral . . . 24
1.4.2 Objetivos específicos . . . 24
1.5 Metodologia resumida . . . 25
1.6 Organização do trabalho . . . 25

2 REFERENCIAL TEÓRICO . . . 27
2.1 Análise de dados em ambiente empresarial . . . 27
2.2 Modelos de linguagem de grande escala . . . 27
2.3 *Text-to-SQL* . . . 28
2.3.1 Definição . . . 28
2.3.2 Evolução . . . 28
2.3.3 Técnicas com modelos de linguagem . . . 28
2.3.4 Conjuntos de avaliação e métricas . . . 29
2.3.5 Limitações em bancos de dados reais . . . 30
2.4 Contexto de negócio e camada semântica . . . 30
2.5 Confiabilidade de modelos de linguagem . . . 31
2.6 Usabilidade e avaliação com usuários . . . 32
2.7 Análise dos trabalhos relevantes . . . 32
2.8 Síntese do capítulo . . . 33

3 PROPOSTA . . . 35
3.1 Visão geral da solução . . . 35
3.2 Requisitos . . . 35
3.3 Arquitetura . . . 36
3.4 Fluxo de uma pergunta . . . 38
3.5 Montagem do contexto . . . 38
3.6 Apresentação da resposta . . . 40
3.7 Escolha do modelo de linguagem . . . 41
3.8 Segurança e privacidade . . . 42
3.9 Banco de perguntas . . . 42
3.10 Tecnologias . . . 42

4 METODOLOGIA . . . 45
4.1 Classificação da pesquisa . . . 45
4.2 Etapas do trabalho . . . 45
4.3 Objetivo de medição . . . 45
4.4 Sujeitos, materiais e procedimentos de coleta . . . 46
4.4.1 Sujeitos e objeto da pesquisa . . . 46
4.4.2 Materiais e equipamentos . . . 47
4.4.3 Procedimentos de coleta de dados . . . 47
4.5 Banco de perguntas e gabarito . . . 47
4.6 Experimento de acurácia . . . 48
4.6.1 Variáveis . . . 48
4.6.2 Procedimento . . . 48
4.6.3 Regra de acerto . . . 48
4.6.4 Classificação dos erros . . . 49
4.7 Estudo com usuários . . . 49
4.8 Análise dos dados . . . 49
4.9 Processo de desenvolvimento do software . . . 50
4.10 Ameaças à validade . . . 50
4.11 Cronograma . . . 50

5 CONSIDERAÇÕES FINAIS . . . 55
5.1 Síntese do trabalho . . . 55
5.2 Objetivos e encaminhamento . . . 55
5.3 Limitações e riscos . . . 55
5.4 Próximos passos . . . 56

REFERÊNCIAS . . . 59

1 Introdução

Este trabalho avalia em que medida o contexto de negócio fornecido a um modelo de linguagem de grande escala afeta a confiabilidade das respostas de um assistente que traduz perguntas em linguagem natural para consultas a bancos de dados empresariais, e se, nessa condição, usuários não técnicos conseguem obter respostas corretas sem o apoio de analistas. Para isso, será desenvolvido um assistente desse tipo, e o efeito do contexto será medido em um experimento controlado e em um estudo com usuários do domínio comercial.

1.1 Contextualização

Em muitas empresas, os dados que respondem a perguntas cotidianas de negócio, como o volume de vendas de um período ou o desempenho de uma equipe, estão registrados em bancos de dados relacionais, mas o acesso a eles exige o domínio da linguagem SQL. Profissionais das áreas de negócio, que em geral não escrevem consultas, dependem então de especialistas para obter esses números (ALPAR; SCHULZ, 2016).

A tarefa de traduzir uma pergunta em linguagem natural para uma consulta SQL, conhecida como *text-to-SQL*, é estudada há décadas e passou por abordagens baseadas em regras, em redes neurais e, mais recentemente, em modelos de linguagem (KATSOGIANNIS-MEIMARAKIS; KOUTRIKA, 2023; HONG et al., 2025). Os *Large Language Models* (LLMs) são capazes de executar tarefas novas a partir de instruções e de poucos exemplos fornecidos no próprio *prompt*, sem treinamento específico (BROWN et al., 2020), o que tornou possível construir assistentes de consulta a dados apenas descrevendo o banco ao modelo. Com isso, a perspectiva de que um usuário não técnico faça perguntas diretamente aos dados da empresa deixou de ser apenas teórica.

1.2 Justificativa

Os conjuntos de avaliação mais utilizados em *text-to-SQL* foram construídos sobre bancos de dados públicos de diversos domínios (YU et al., 2018), com esquemas relativamente simples e pouca necessidade de conhecimento externo ao esquema (LI et al., 2023). Em bancos empresariais, por outro lado, o significado de uma métrica costuma depender de regras de negócio que não aparecem no esquema, como o critério que define quando um contrato conta como venda ou qual data deve ser usada para atribuí-lo a um período. Trabalhos recentes passaram a incorporar esse tipo de conhecimento externo à avaliação e mostraram que bancos maiores e mais realistas tornam a tarefa consideravelmente mais

difícil, mesmo para os modelos mais avançados (LI et al., 2023). Ainda há, porém, pouca evidência sobre o efeito do contexto de negócio em bancos de dados de uma empresa real, consultados por seus próprios usuários.

Do ponto de vista prático, o problema é agravado pela natureza do erro. Modelos de linguagem podem produzir respostas fluentes e plausíveis que não são sustentadas pelos dados (JI et al., 2023), e, em *text-to-SQL*, isso se manifesta como uma consulta válida que retorna um número errado. Para um analista, esse tipo de erro pode ser detectado pela leitura da consulta; para um usuário não técnico, ele é invisível, e uma decisão baseada em um número incorreto pode ser pior do que a ausência de resposta. Medir quanto o contexto de negócio reduz esses erros e se, com ele, usuários não técnicos ganham autonomia de fato é, portanto, relevante tanto para a pesquisa quanto para empresas que consideram adotar esse tipo de assistente.

1.3 Problema de pesquisa

Diante desse cenário, o trabalho busca responder à seguinte pergunta: em que medida o nível de contexto de negócio fornecido ao LLM afeta a acurácia das respostas e a autonomia de usuários não técnicos?

1.4 Objetivos

1.4.1 Objetivo geral

Avaliar em que medida o nível de contexto de negócio fornecido a um LLM afeta a acurácia de um assistente *text-to-SQL* e a autonomia de usuários não técnicos na análise de dados empresariais do domínio comercial.

1.4.2 Objetivos específicos

1. Construir um banco de 20 perguntas de negócio do domínio comercial, com consulta SQL de referência e resultado esperado.

2. Desenvolver um assistente *text-to-SQL* capaz de operar em três configurações de contexto de negócio: esquema puro, esquema documentado e camada semântica.

3. Medir a acurácia de execução do assistente em cada configuração e classificar os erros segundo uma taxonomia.

4. Avaliar a autonomia de usuários não técnicos na configuração de melhor desempenho, por meio da taxa de acerto em tarefas, do tempo de execução e da escala SUS.

1.5 Metodologia resumida

A pesquisa é aplicada e experimental. O contexto de negócio será a variável manipulada, em três configurações cumulativas: apenas o esquema das tabelas, o esquema acrescido de descrições escritas pelo usuário e, por fim, o esquema documentado acrescido das regras de negócio. No experimento principal, o mesmo banco de perguntas será executado nas três configurações com um único modelo de linguagem, e a acurácia de execução será comparada por testes estatísticos pareados. Em seguida, de 5 a 8 usuários não técnicos realizarão tarefas na configuração de melhor desempenho, com medição de acerto, tempo e usabilidade. O detalhamento está no Capítulo 4.

1.6 Organização do trabalho

Além desta introdução, o trabalho está organizado da seguinte forma. O Capítulo 2 apresenta os conceitos de modelos de linguagem, *text-to-SQL*, contexto de negócio e camada semântica, confiabilidade de modelos de linguagem e avaliação de usabilidade, além de uma análise dos trabalhos relevantes. O Capítulo 3 descreve o assistente proposto: requisitos, arquitetura, montagem do contexto, escolha do modelo e banco de perguntas. O Capítulo 4 apresenta o desenho do experimento de acurácia e do estudo com usuários, a análise dos dados, as ameaças à validade e o cronograma do TCC2. Por fim, o Capítulo 5 retoma os objetivos, registra limitações e riscos e apresenta os próximos passos.

2 Referencial teórico

Este capítulo apresenta os conceitos que fundamentam o trabalho. Inicialmente, discute-se a análise de dados em ambiente empresarial e a dependência de usuários de negócio em relação a analistas. Em seguida, são tratados os modelos de linguagem de grande escala, a tarefa de *text-to-SQL* e as formas de avaliá-la, o papel do contexto de negócio e da camada semântica e a confiabilidade das respostas de modelos de linguagem. Por fim, são apresentados os conceitos de usabilidade usados no estudo com usuários, uma análise dos trabalhos relevantes e uma síntese do capítulo.

2.1 Análise de dados em ambiente empresarial

Os sistemas de *Business Intelligence* (BI) reúnem dados de diferentes fontes da organização e os disponibilizam para consulta e análise, apoiando a tomada de decisão. Tradicionalmente, a construção de relatórios e consultas nesses sistemas cabe a especialistas em tecnologia da informação ou em análise de dados, enquanto os usuários de negócio consomem os resultados (ALPAR; SCHULZ, 2016). Esse arranjo cria uma fila de demandas: cada nova pergunta precisa ser traduzida por um especialista, o que limita a velocidade e o alcance da análise.

O *self-service* BI surgiu como resposta a esse problema, com o objetivo de permitir que os próprios usuários de negócio acessem e analisem os dados com menor dependência da área técnica (ALPAR; SCHULZ, 2016). Na revisão de Lennerholt, Laere e Söderström (2018) sobre a implantação dessas soluções, porém, aparecem desafios recorrentes, entre eles a dificuldade dos usuários em compreender os dados disponíveis e em utilizar as ferramentas sem apoio. Mesmo quando a ferramenta oferece uma interface amigável, o usuário precisa saber onde está a informação e como as métricas são definidas, o que mantém parte da dependência em relação aos especialistas.

2.2 Modelos de linguagem de grande escala

Os *Large Language Models* (LLMs) são redes neurais treinadas sobre grandes volumes de texto para prever a continuação de uma sequência de *tokens*. A maior parte desses modelos se baseia na arquitetura *Transformer*, que utiliza mecanismos de atenção para relacionar cada elemento da sequência com os demais (VASWANI et al., 2017).

Uma propriedade central desses modelos é o aprendizado em contexto (*in-context learning*): o modelo é capaz de executar uma tarefa nova a partir de uma descrição em

linguagem natural e, opcionalmente, de alguns exemplos incluídos na própria entrada, sem ajuste de seus parâmetros (BROWN et al., 2020). A entrada fornecida ao modelo, chamada de *prompt*, torna-se assim o principal meio de especificar a tarefa e de fornecer as informações necessárias para resolvê-la. Para o presente trabalho, isso significa que o esquema do banco de dados e o contexto de negócio podem ser comunicados ao modelo simplesmente por meio do *prompt*.

Quando a resposta do modelo precisa ser processada por um programa, e não apenas lida por uma pessoa, é necessário que ela siga um formato previsível. Interfaces de programação de modelos comerciais oferecem, para isso, a geração de saídas estruturadas, em que a resposta obedece a um esquema JSON definido pela aplicação (OPENAI, 2026c).

2.3 *Text-to-SQL*

2.3.1 Definição

Text-to-SQL é a tarefa de traduzir uma pergunta em linguagem natural para uma consulta SQL que, executada sobre um banco de dados, retorna a resposta à pergunta (KATSOGIANNIS-MEIMARAKIS; KOUTRIKA, 2023). Neste trabalho, a tarefa é formulada como na Eq. 2.1, em que um modelo M recebe a pergunta q, o esquema S do banco de dados e um contexto adicional K e produz a consulta $\hat{y}$:

$$\hat{y} = M(q, S, K), \tag{2.1}$$

em que K pode ser vazio. A variação de K é justamente o objeto do experimento descrito no Capítulo 4.

2.3.2 Evolução

As primeiras interfaces em linguagem natural para bancos de dados baseavam-se em regras e gramáticas construídas manualmente para domínios específicos. Com o aprendizado profundo, passaram a predominar modelos neurais treinados sobre pares de perguntas e consultas, capazes de generalizar para bancos de dados não vistos no treinamento (KATSOGIANNIS-MEIMARAKIS; KOUTRIKA, 2023). Mais recentemente, os LLMs passaram a ser empregados diretamente na tarefa, frequentemente sem treinamento específico, guiados apenas pelo *prompt* (HONG et al., 2025).

2.3.3 Técnicas com modelos de linguagem

As abordagens baseadas em LLMs diferem principalmente na forma como o problema é apresentado ao modelo. A representação do esquema no *prompt*, a seleção de exemplos de perguntas resolvidas e a organização desses exemplos influenciam de maneira

significativa a acurácia obtida (GAO et al., 2024). Outra linha decompõe a tarefa em etapas, como a identificação das tabelas e colunas relevantes, a classificação da complexidade da pergunta e a geração da consulta, e acrescenta uma etapa de autocorreção, em que o modelo revisa a própria consulta (POURREZA; RAFIEI, 2023). Há também propostas que geram, antes da consulta, o conhecimento de domínio necessário para respondê-la, como definições e fórmulas (HONG et al., 2024).

2.3.4 Conjuntos de avaliação e métricas

O Spider é um conjunto de avaliação de *text-to-SQL* entre domínios, construído para medir a capacidade de generalização para bancos de dados não vistos no treinamento (YU et al., 2018). O BIRD foi proposto para aproximar a avaliação de cenários reais, com bancos de dados maiores, valores com ruído e a necessidade de conhecimento externo ao esquema, fornecido na forma de evidências que acompanham cada pergunta (LI et al., 2023). A Tab. 1 compara as duas propostas.

Tabela 1 – Comparação entre os conjuntos de avaliação Spider e BIRD

Característica	**Spider**	**BIRD**
Perguntas	10.181	12.751 pares de pergunta e consulta
Bancos de dados	200, de 138 domínios	95, de 37 domínios profissionais
Conhecimento externo ao esquema	Não fornecido	Fornecido como evidência por pergunta
Ênfase	Generalização para novos bancos	Bancos grandes e realistas

Fonte: Elaborado pelo autor com base em Yu et al. (2018) e Li et al. (2023).

Duas métricas são usuais na área. A correspondência exata (*exact match*) compara a estrutura da consulta gerada com a da consulta de referência, componente a componente (YU et al., 2018). A acurácia de execução (*execution accuracy*) executa as duas consultas e as considera equivalentes quando produzem o mesmo resultado (LI et al., 2023). A primeira penaliza consultas corretas escritas de forma diferente da referência, enquanto a segunda avalia o que o usuário efetivamente recebe. Formalmente, para um conjunto de N perguntas, a acurácia de execução é dada pela Eq. 2.2:

$$EX = \frac{1}{N} \sum_{i=1}^{N} \mathbf{1} \left[R(\hat{y}_i) = R(y_i) \right], \tag{2.2}$$

em que $R(\cdot)$ é o resultado da execução de uma consulta, y_i é a consulta de referência da pergunta i e $\mathbf{1}[\cdot]$ vale 1 quando a condição é verdadeira e 0 caso contrário. Este trabalho adota a acurácia de execução como métrica principal, com os critérios de equivalência definidos na Seção 4.6.3.

2.3.5 Limitações em bancos de dados reais

O desempenho dos modelos cai de forma expressiva quando a avaliação passa de bancos simples para bancos maiores, com valores reais e dependência de conhecimento externo, e permanece distante do desempenho humano (LI et al., 2023). Em bancos empresariais, a distância entre a estrutura e o significado dos dados tende a ser ainda maior: nomes de colunas podem ser abreviados ou ambíguos, valores podem seguir códigos internos, e o critério de cálculo de uma métrica pode não estar registrado em lugar algum do esquema. Nesses casos, a dificuldade não está na sintaxe SQL, mas em saber o que a pergunta significa para aquela organização.

2.4 Contexto de negócio e camada semântica

O esquema de um banco de dados descreve a estrutura dos dados: tabelas, colunas, tipos e relacionamentos. O significado desses dados para a organização, isto é, o que cada registro representa, o que significa cada código e como cada métrica deve ser calculada, constitui o que este trabalho chama de contexto de negócio.

Em projetos de BI, esse significado é registrado em metadados e em definições de negócio consistentes, compartilhadas entre as áreas, para que uma mesma métrica não seja calculada de formas diferentes em relatórios distintos (KIMBALL; ROSS, 2013). Esses elementos incluem descrições de tabelas e colunas, como em um dicionário de dados, e regras de negócio, como os critérios que definem uma venda ou o período ao qual ela pertence. Ao conjunto estruturado dessas definições, posicionado entre os dados e as ferramentas de consulta, dá-se o nome de camada semântica.

Em *text-to-SQL*, o mesmo tipo de informação aparece como conhecimento externo ao esquema, que pode ser fornecido ao modelo junto com a pergunta (LI et al., 2023) ou gerado por um modelo auxiliar (HONG et al., 2024). Este trabalho organiza o contexto de negócio em três níveis cumulativos, que correspondem às configurações descritas na Seção 3.5: o esquema puro (C0), o esquema acrescido das descrições de tabelas e colunas (C1) e o esquema documentado acrescido das regras de negócio, que compõe a camada semântica (C2).

A Figura 1 ilustra como a falta de contexto produz um erro que não é de sintaxe, mas de significado. O exemplo é hipotético e usa uma tabela de contratos em que a regra de negócio determina que uma venda só ocorre quando o contrato é assinado e pertence ao mês da assinatura.

As duas consultas são válidas e retornam um número. Sem a regra, porém, o modelo conta contratos criados no período, incluindo os não assinados e excluindo os assinados em março que foram criados antes, e o usuário não tem como perceber a diferença apenas

Figura 1 – Consulta válida com resultado incorreto por falta de contexto

```
Pergunta: Quantas vendas houve em marco de 2026?

Sem a regra de negocio (resultado incorreto):
  SELECT COUNT(*) FROM contratos
  WHERE data_criacao BETWEEN '2026-03-01' AND '2026-03-31';

Com a regra de negocio (resultado correto):
  SELECT COUNT(*) FROM contratos
  WHERE status = 'assinado'
    AND data_assinatura BETWEEN '2026-03-01' AND '2026-03-31';

Regra: um contrato conta como venda apenas quando assinado,
       no mes da data de assinatura.
```

Fonte: Elaborado pelo autor.

olhando o resultado.

Para dimensionar o efeito, suponha-se, ainda de forma hipotética, que em março de 2026 tenham sido criados 40 contratos, dos quais 25 foram assinados no próprio mês, 10 seguiam aguardando assinatura e 5 foram cancelados, e que outros 8 contratos, criados em fevereiro, tenham sido assinados em março. A primeira consulta retornaria 40 vendas, e a segunda, 33 (os 25 contratos criados e assinados em março somados aos 8 criados antes e assinados no mês). O valor incorreto superestima as vendas em cerca de 21%, pois soma 15 contratos que não foram vendas e deixa de fora 8 que foram. O erro, portanto, não decorre de falta de competência do modelo em SQL, e sim da ausência de uma informação que só a organização possui. Por esse motivo, este trabalho avalia as respostas pelo resultado produzido, e não pela validade da consulta, e classifica erros dessa natureza na categoria de filtro ou regra de negócio (Seção 4.6.4).

2.5 Confiabilidade de modelos de linguagem

Modelos de linguagem podem produzir conteúdo fluente e plausível, mas sem sustentação nas informações disponíveis, fenômeno conhecido como alucinação (JI et al., 2023). Em *text-to-SQL*, a alucinação pode se manifestar como referências a colunas inexistentes, que resultam em consultas inválidas, ou como interpretações equivocadas da pergunta, que resultam em consultas válidas com resultados incorretos.

O segundo caso é o mais crítico para o usuário não técnico. Uma consulta inválida produz um erro visível, mas uma consulta válida com resultado incorreto produz um número que parece legítimo. Como esse usuário não lê SQL, ele não tem meios de verificar a

resposta, e a confiança no assistente passa a depender inteiramente da acurácia do modelo.

Outro aspecto da confiabilidade é a estabilidade das respostas. A mesma pergunta, submetida mais de uma vez ao mesmo modelo, pode gerar consultas diferentes, o que exige que a avaliação considere repetições e meça a consistência dos resultados.

2.6 Usabilidade e avaliação com usuários

A norma ISO 9241-11 define usabilidade como a medida em que um sistema pode ser usado por usuários específicos para alcançar objetivos específicos com eficácia, eficiência e satisfação em um contexto de uso específico (BEVAN; CARTER; HARKER, 2015). Essas três dimensões orientam as métricas do estudo com usuários deste trabalho, conforme a Tab. 2.

Tabela 2 – Dimensões de usabilidade e métricas correspondentes no estudo com usuários

Dimensão	**Significado**	**Métrica no estudo**
Eficácia	Alcançar o objetivo corretamente	Taxa de acerto das tarefas
Eficiência	Recursos gastos para alcançar o objetivo	Tempo por tarefa
Satisfação	Percepção do usuário sobre o uso	Escore SUS

Fonte: Elaborado pelo autor com base em Bevan, Carter e Harker (2015).

A *System Usability Scale* (SUS) é um questionário de dez afirmações, respondidas em escala de cinco pontos, que resulta em um escore de 0 a 100 (BROOKE, 1996). Por ser curta e independente da tecnologia avaliada, tornou-se um dos instrumentos mais utilizados para medir a usabilidade percebida (LEWIS, 2018). Estudos posteriores propuseram faixas de interpretação que associam o escore a níveis de aceitabilidade e a notas, o que permite situar o resultado de um sistema em relação a outros (BANGOR; KORTUM; MILLER, 2008; LEWIS, 2018).

Quanto ao número de participantes, Nielsen e Landauer (1993) mostraram que estudos com poucos usuários já revelam a maior parte dos problemas de usabilidade de uma interface, com retornos decrescentes à medida que mais participantes são incluídos. Esse resultado justifica estudos exploratórios com amostras pequenas, desde que seus resultados sejam tratados como indicativos, e não como generalizáveis estatisticamente.

2.7 Análise dos trabalhos relevantes

Foram analisados os trabalhos mais próximos deste: os conjuntos de avaliação Spider (YU et al., 2018) e BIRD (LI et al., 2023) e as abordagens DAIL-SQL (GAO et al., 2024), DIN-SQL (POURREZA; RAFIEI, 2023) e Knowledge-to-SQL (HONG et al., 2024). A Tab. 3 os compara quanto ao tipo de base em que foram avaliados, ao tratamento do conhecimento de negócio e à presença de avaliação com usuários.

Tabela 3 – Comparação entre os trabalhos relevantes e este trabalho

Trabalho	**Base de avaliação**	**Conhecimento de negócio**	**Usuários reais**
Spider	Bancos públicos de múltiplos domínios	Não considerado	Não
BIRD	Bancos públicos grandes e realistas	Fornecido como evidência por pergunta	Não
DAIL-SQL	Conjuntos públicos	Não considerado; foco na representação do *prompt*	Não
DIN-SQL	Conjuntos públicos	Não considerado; foco na decomposição da tarefa	Não
Knowledge-to-SQL	Conjuntos públicos	Gerado por um modelo auxiliar	Não
Este trabalho	Banco de uma empresa real	Manipulado em três níveis	Sim

Fonte: Elaborado pelo autor.

Os trabalhos analisados mostram que o conhecimento externo ao esquema afeta a acurácia (LI et al., 2023; HONG et al., 2024) e que a forma de apresentar o problema ao modelo também a afeta (GAO et al., 2024; POURREZA; RAFIEI, 2023). Todos, porém, foram avaliados em conjuntos públicos, nos quais o conhecimento de negócio é fornecido pelos autores do conjunto, e não pelos usuários da organização, e nenhum mediu se usuários não técnicos conseguem, de fato, obter respostas corretas. Este trabalho se diferencia em três pontos: o contexto de negócio é escrito pelo próprio usuário na interface do assistente, seu efeito é medido de forma controlada em um banco de dados empresarial real, e a avaliação inclui usuários não técnicos do domínio.

2.8 Síntese do capítulo

A Tab. 4 relaciona os conceitos apresentados neste capítulo às partes do trabalho em que são utilizados.

Tabela 4 – Conceitos do referencial teórico e seu uso no trabalho

Conceito	**Uso no trabalho**
Self-service BI	Motivação: reduzir a dependência de analistas
Aprendizado em contexto e *prompt*	Meio de fornecer esquema e contexto ao modelo (Capítulo 3)
Saída estruturada	Formato das respostas do modelo no assistente
Formulação de *text-to-SQL*	Definição da variável K manipulada no experimento
Acurácia de execução	Métrica principal do experimento (Capítulo 4)
Contexto de negócio e camada semântica	Configurações C0, C1 e C2
Alucinação e estabilidade	Classificação dos erros e medida de consistência
Usabilidade (ISO 9241-11) e SUS	Métricas do estudo com usuários
Estudos com poucos usuários	Justificativa do tamanho da amostra

Fonte: Elaborado pelo autor.

3 Proposta

Este capítulo apresenta o assistente *text-to-SQL* que será desenvolvido e avaliado no trabalho. São descritos os requisitos, a arquitetura, o caminho percorrido por uma pergunta até a resposta, a forma como o contexto de negócio é montado em cada configuração experimental, a apresentação da resposta ao usuário, a escolha do modelo de linguagem, os cuidados de segurança e privacidade, a estrutura do banco de perguntas e as tecnologias adotadas. O modo como o assistente será avaliado é tratado no capítulo de Metodologia.

3.1 Visão geral da solução

Profissionais da área de negócio costumam depender de analistas de dados para obter números que já estão registrados nos sistemas da empresa. Os *Large Language Models* (LLMs) permitem traduzir uma pergunta em linguagem natural para uma consulta *Structured Query Language* (SQL), o que, em princípio, reduziria essa dependência. Em bancos de dados empresariais, porém, o significado de uma métrica costuma estar em regras de negócio que não aparecem no esquema das tabelas, e o modelo pode gerar uma consulta válida que responde a uma pergunta diferente da que foi feita.

O assistente proposto parte dessa constatação e trata o contexto de negócio como uma entrada explícita do sistema. O uso previsto segue quatro passos: (i) o usuário anexa as tabelas do domínio como arquivos *Comma-Separated Values* (CSV); (ii) escreve, para cada tabela, uma descrição em linguagem natural e, opcionalmente, as regras de negócio que se aplicam a ela; (iii) faz perguntas em linguagem natural; e (iv) recebe a resposta na forma de um texto interpretativo, um gráfico interativo e uma tabela. O banco de dados é montado exclusivamente a partir dos arquivos anexados, e o assistente não altera dados a partir das perguntas do usuário.

3.2 Requisitos

Os requisitos do assistente são apresentados na Tab. 5. Cada requisito recebe um identificador, de modo que possa ser rastreado até os componentes da arquitetura (Seção 3.3) e até as tarefas do cronograma de desenvolvimento. Os requisitos funcionais (RF) descrevem o que o sistema faz, e os requisitos não funcionais (RNF) descrevem restrições sobre como ele o faz. Os requisitos RF06 e RF07 existem para viabilizar o experimento e não fazem parte do uso cotidiano previsto para o usuário não técnico.

Tabela 5 – Requisitos funcionais e não funcionais do assistente

ID	Requisito
RF01	Anexar uma ou mais tabelas em formato CSV.
RF02	Cadastrar e editar uma descrição em linguagem natural para cada tabela e, opcionalmente, para cada coluna.
RF03	Cadastrar regras de negócio e definições de métricas (glossário).
RF04	Receber perguntas em linguagem natural e responder com base nos dados anexados.
RF05	Exibir a consulta SQL gerada apenas em modo avançado.
RF06	Selecionar a configuração de contexto utilizada (C0, C1 ou C2).
RF07	Executar o banco de perguntas em lote e registrar os resultados de cada execução.
RF08	Apresentar um texto em linguagem natural que interpreta o resultado obtido.
RF09	Apresentar um gráfico interativo adequado ao resultado, com destaque para a evolução temporal quando houver uma dimensão de tempo.
RNF01	Executar apenas consultas de leitura sobre o banco de dados.
RNF02	Registrar, para cada execução, o *prompt*, a consulta gerada, o resultado, o tempo e o custo.
RNF03	Manter fixos, durante o experimento, a versão do modelo e a temperatura (zero).
RNF04	Limitar o tempo de execução das consultas e o número de linhas retornadas.
RNF05	Oferecer interface em português, utilizável por quem não conhece SQL.

Fonte: Elaborado pelo autor.

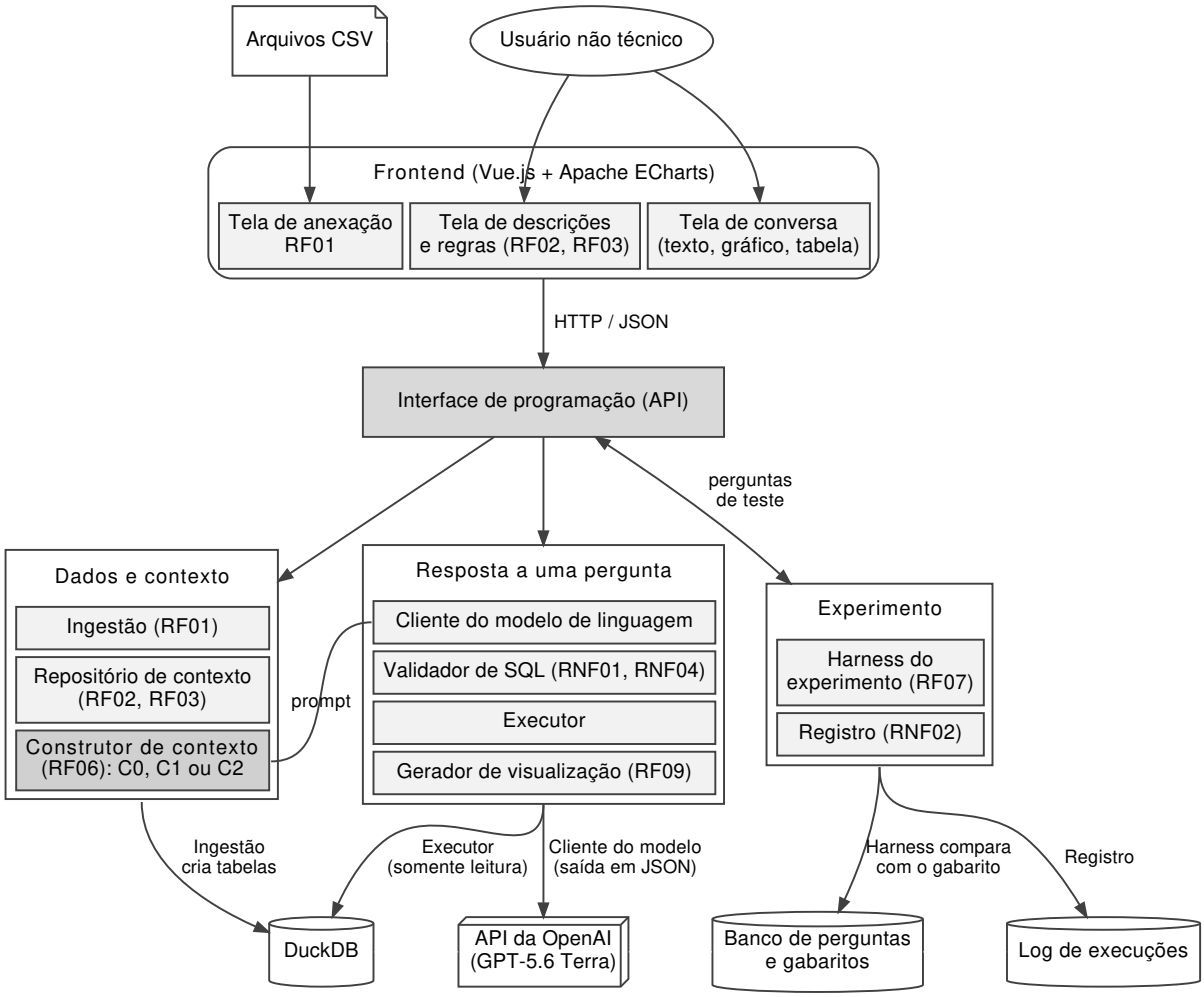
3.3 Arquitetura

O assistente será organizado em um *frontend web*, responsável pela interação com o usuário, e um *backend*, responsável pela ingestão dos dados, pela montagem do contexto, pela comunicação com o modelo de linguagem e pela execução das consultas. A Figura 2 apresenta os componentes do *backend* organizados em três grupos: dados e contexto, resposta a uma pergunta e experimento. A interface de programação recebe as requisições do *frontend* e coordena os grupos, que dependem de três recursos externos: o banco de dados DuckDB, a API do modelo de linguagem e o banco de perguntas do experimento.

Os componentes têm as seguintes responsabilidades:

- ***Frontend*:** oferece as telas de anexação de arquivos, de cadastro de descrições e regras e de conversa, além de exibir a resposta (RF01 a RF05, RF08, RF09, RNF05).
- **Interface de programação (API):** expõe ao *frontend* as operações de ingestão,

Figura 2 – Arquitetura do assistente



Fonte: Elaborado pelo autor.

de gestão do contexto e de resposta a perguntas.

- **Ingestão:** carrega cada arquivo CSV como uma tabela do banco de dados, infere os tipos das colunas e guarda os metadados de cada tabela (nomes e tipos de colunas e uma pequena amostra de linhas) (RF01).

- **Repositório de contexto:** armazena as descrições de tabelas e colunas e as regras de negócio informadas pelo usuário (RF02, RF03).

- **Construtor de contexto:** monta o *prompt* enviado ao modelo de acordo com a configuração selecionada (RF06). É o único componente cujo comportamento varia entre as configurações do experimento (Seção 3.5).

- **Cliente do modelo de linguagem:** realiza as chamadas à API do modelo e solicita respostas em formato estruturado.

- **Validador de SQL:** rejeita qualquer comando que não seja uma consulta de leitura e impõe limites de linhas e de tempo (RNF01, RNF04).
- **Executor:** executa a consulta validada sobre o banco de dados e devolve o resultado.
- **Gerador de visualização:** confere a sugestão de gráfico feita pelo modelo contra as colunas do resultado e produz a configuração do gráfico (RF09).
- **Registro:** grava cada execução com os dados necessários à reprodução do experimento (RNF02).
- ***Harness* do experimento:** executa o banco de perguntas em todas as configurações e repetições e compara cada resultado com o gabarito (RF07).

3.4 Fluxo de uma pergunta

A Figura 3 mostra o caminho de uma pergunta desde o envio pelo usuário até a exibição da resposta, em nove passos numerados. Cada pergunta envolverá duas chamadas ao modelo de linguagem, destacadas em cinza mais escuro na figura (passos 3 e 7).

Na primeira chamada, de geração, o modelo recebe a pergunta e o contexto montado conforme a configuração ativa e devolve, em formato estruturado, a consulta SQL e uma sugestão de gráfico (tipo e colunas de cada eixo). A consulta passa pelo validador e, se aprovada, é executada sobre o banco de dados. Na segunda chamada, de interpretação, o modelo recebe a pergunta e o resultado efetivamente obtido e redige um texto curto que o descreve.

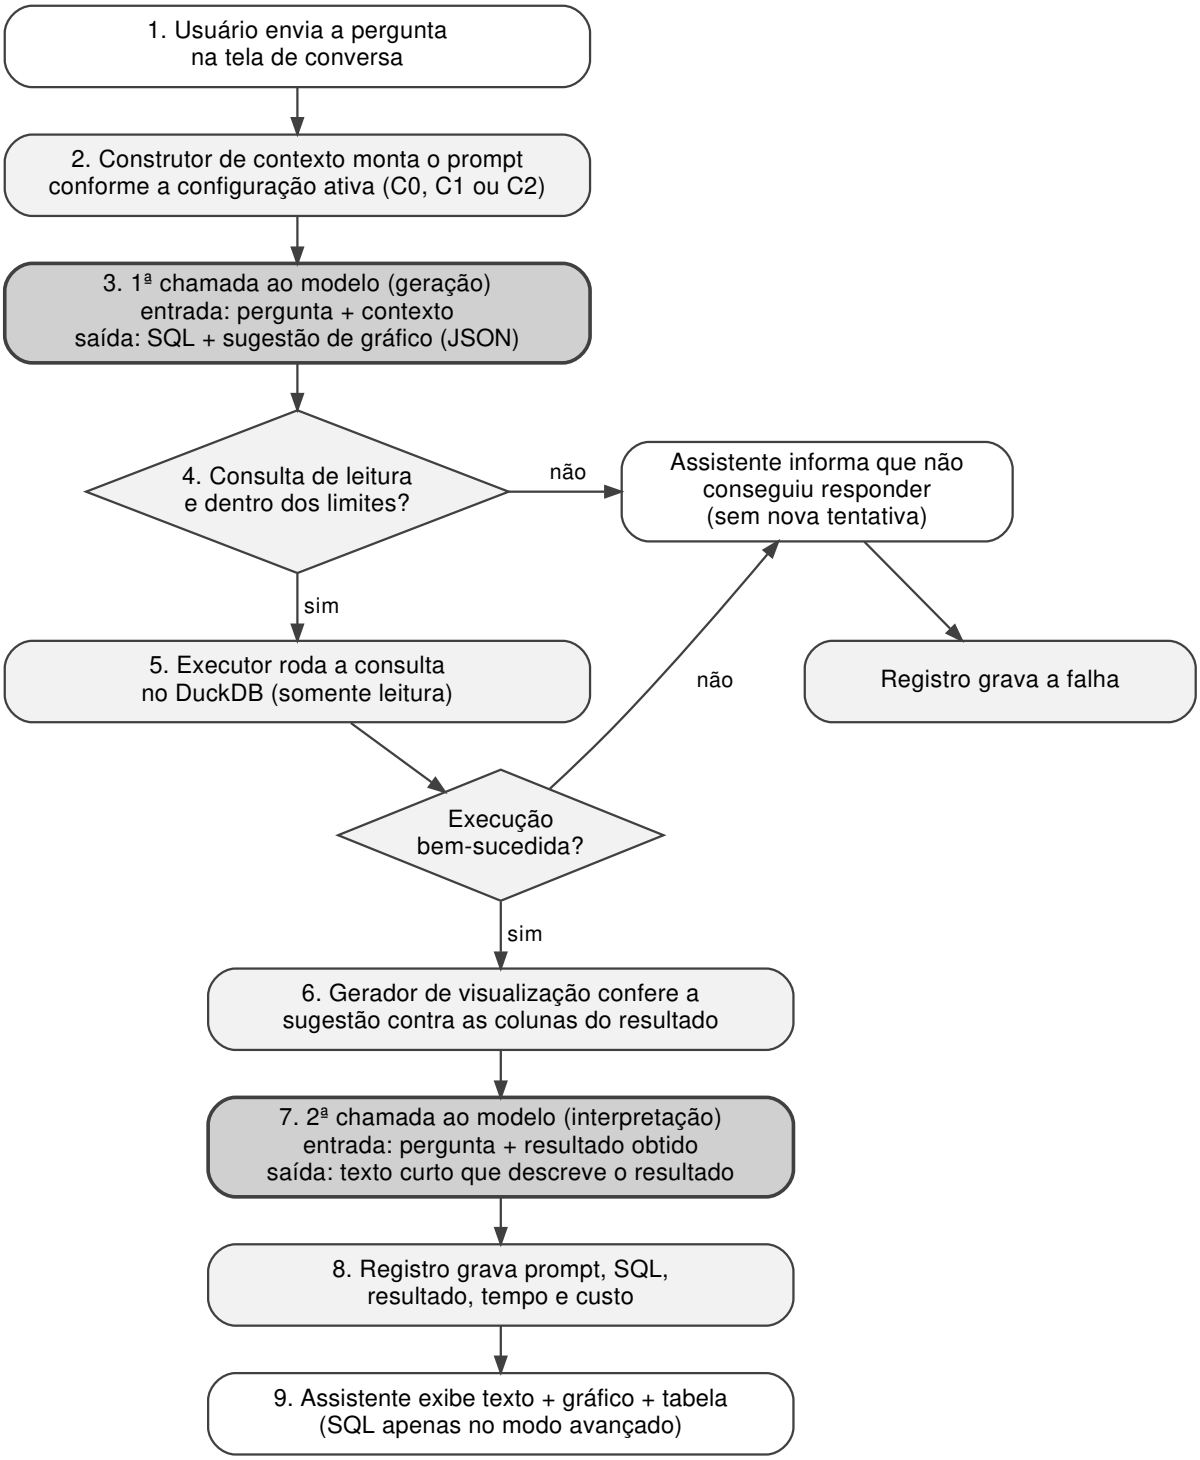
A separação em duas chamadas é intencional. Como os modelos de linguagem podem produzir conteúdo não sustentado pelas evidências disponíveis (JI et al., 2023), o texto interpretativo só é gerado depois da execução, para que descreva os números retornados pelo banco, e não valores estimados pelo modelo antes de conhecê-los.

Se a consulta gerada for rejeitada pelo validador ou falhar ao ser executada, o assistente informará ao usuário que não conseguiu responder, sem nova tentativa. Técnicas de autocorreção, em que o erro é devolvido ao modelo para uma segunda tentativa, são conhecidas na literatura (POURREZA; RAFIEI, 2023), mas não serão adotadas. Essa decisão mantém o experimento centrado no efeito do contexto de negócio: com autocorreção, a acurácia medida passaria a refletir também a capacidade de recuperação do modelo.

3.5 Montagem do contexto

O contexto de negócio é a variável manipulada no experimento. A forma como o esquema e as informações adicionais são representadas no *prompt* influencia o desempenho

Figura 3 – Fluxo de uma pergunta no assistente



Fonte: Elaborado pelo autor.

de modelos de linguagem em tarefas *text-to-SQL* (GAO et al., 2024), e conjuntos de avaliação recentes passaram a fornecer conhecimento externo ao esquema, como definições e fórmulas, para aproximar a tarefa de bancos reais (LI et al., 2023). O assistente oferecerá três configurações cumulativas, cada uma acrescentando informação à anterior, conforme a Tab. 6.

Tabela 6 – Configurações de contexto de negócio

Config.	**Informação fornecida ao modelo**	**Origem no assistente**
C0	Nomes das tabelas e colunas, tipos e amostra de linhas	Inferida automaticamente na ingestão dos CSVs
C1	C0 acrescida da descrição de cada tabela e, quando houver, de cada coluna	Escrita pelo usuário na tela de descrições (RF02)
C2	C1 acrescida das regras de negócio e definições de métricas	Escrita pelo usuário na tela de regras (RF03)

Fonte: Elaborado pelo autor.

Como cada configuração corresponde exatamente ao que o usuário preenche na interface, o resultado do experimento poderá ser lido como uma recomendação prática: quanto se ganha em acurácia ao descrever as tabelas e ao registrar as regras de negócio. Todos os demais elementos do *prompt*, como as instruções gerais e o formato de saída exigido, serão idênticos nas três configurações.

A Figura 4 ilustra o contexto gerado para uma mesma tabela nas três configurações. A tabela é hipotética e serve apenas para ilustrar a diferença entre as configurações, uma vez que as tabelas do experimento ainda serão definidas.

No exemplo, uma pergunta como “quantas vendas houve em março?” pode ser respondida em C0 com uma contagem de todos os contratos criados em março. A consulta seria válida e retornaria um número, mas esse número estaria errado segundo a regra de negócio, que só passa a estar disponível ao modelo em C2.

3.6 Apresentação da resposta

A resposta ao usuário reunirá três elementos: o texto interpretativo (RF08), um gráfico interativo (RF09) e a tabela com o resultado. A consulta SQL ficará oculta por padrão e poderá ser exibida em modo avançado (RF05), útil para auditoria e para usuários com conhecimento técnico.

O tipo de gráfico será escolhido a partir da sugestão feita pelo modelo na chamada de geração. Como essa sugestão pode citar colunas inexistentes ou inadequadas, o gerador

Figura 4 – Contexto de uma tabela nas configurações C0, C1 e C2

```
[C0] Tabela contratos(id INTEGER, cliente_id INTEGER, valor DECIMAL,
     data_criacao DATE, data_assinatura DATE, status VARCHAR)
     Amostra: (101, 7, 4500.00, 2026-03-02, 2026-03-10, 'assinado')

[C1] C0 +
     Descricao: um registro por contrato enviado a um cliente.
     status: 'enviado', 'assinado' ou 'cancelado'.
     data_criacao: dia em que o contrato foi gerado.
     data_assinatura: dia em que o cliente assinou (nula se nao assinou).

[C2] C1 +
     Regra: um contrato so conta como venda quando status = 'assinado'.
     Regra: vendas sao atribuidas ao mes de data_assinatura,
            nunca ao de data_criacao.
```

Fonte: Elaborado pelo autor.

de visualização a conferirá contra as colunas efetivamente retornadas. Quando a sugestão for inválida, o tipo será escolhido por regras simples baseadas no formato do resultado: uma coluna de data e uma numérica resultam em gráfico de linhas, que evidencia a evolução no tempo; uma coluna categórica e uma numérica resultam em gráfico de barras; e um único valor é exibido como indicador numérico. Os gráficos permitirão aproximar regiões, consultar valores ao passar o cursor e ocultar séries.

O texto interpretativo e o gráfico não fazem parte da métrica principal do experimento, que avalia apenas o resultado da consulta. A utilidade desses elementos para o usuário não técnico será observada qualitativamente no estudo com usuários.

3.7 Escolha do modelo de linguagem

O assistente utilizará um único modelo de linguagem, o GPT-5.6 Terra (identificador `gpt-5.6-terra`), acessado pela API da OpenAI (OPENAI, 2026b). A comparação entre modelos está fora do escopo do trabalho, de modo que a escolha não será objeto de medição, mas será justificada pelos seguintes critérios:

- **Desempenho em geração de SQL:** resultados publicados ou recomendação documentada do fornecedor para tarefas de geração de código e consultas estruturadas;
- **Recursos da API:** suporte a respostas que seguem um esquema JSON definido pela aplicação (OPENAI, 2026c) e janela de contexto de 1.050.000 *tokens* (OPENAI, 2026b), suficiente para a configuração C2, a mais extensa;

- **Custo:** custo estimado para as execuções do experimento e do estudo com usuários;
- **Reprodutibilidade:** disponibilidade de versões datadas (*snapshots*) do modelo, que podem ser mantidas fixas durante todo o experimento (OPENAI, 2026b);
- **Privacidade:** política do fornecedor sobre retenção e uso dos dados enviados pela API (OPENAI, 2026a).

O uso de um único modelo limita a generalização dos resultados: outro modelo pode reagir de forma diferente ao mesmo contexto de negócio. Essa limitação é discutida entre as ameaças à validade, no capítulo de Metodologia.

3.8 Segurança e privacidade

Como as consultas executadas são geradas por um modelo de linguagem, o assistente não confiará no texto gerado. O validador aceitará apenas consultas de leitura, a conexão com o banco de dados será aberta em modo somente leitura, e toda consulta terá limite de linhas retornadas e de tempo de execução (RNF01, RNF04). Assim, mesmo uma consulta incorreta ou maliciosa não poderá alterar os dados nem sobrecarregar o sistema.

O assistente enviará ao fornecedor do modelo o contexto das tabelas, que inclui uma amostra de linhas, e, na chamada de interpretação, parte do resultado das consultas. Por esse motivo, os dados utilizados no experimento serão avaliados quanto à presença de dados pessoais e, quando necessário, anonimizados antes da ingestão, em observância à Lei Geral de Proteção de Dados Pessoais (LGPD) (BRASIL, 2018).

3.9 Banco de perguntas

O experimento utilizará um banco de 20 perguntas do domínio comercial. Cada item seguirá o formato da Tab. 7, inspirado nos conjuntos de avaliação de *text-to-SQL*, que associam cada pergunta em linguagem natural a uma consulta de referência (YU et al., 2018; LI et al., 2023).

A estratificação permitirá verificar em que tipo de pergunta o contexto de negócio produz maior ganho. As perguntas e os gabaritos serão validados por analistas da área de negócio e congelados antes da primeira execução do experimento. O conteúdo das perguntas depende das tabelas do domínio comercial que serão utilizadas, ainda a definir.

3.10 Tecnologias

As tecnologias previstas para o desenvolvimento são as seguintes:

Tabela 7 – Campos de cada item do banco de perguntas

Campo	Conteúdo
`id`	Identificador do item.
`pergunta`	Pergunta redigida como um usuário não técnico a faria.
`estrato`	Tipo de dificuldade: simples, com junção de tabelas, dependente de regra de negócio ou ambígua.
`sql_gabarito`	Consulta SQL de referência, escrita pelo autor.
`resultado_esperado`	Resultado da execução da consulta de referência.
`regra_envolvida`	Regra de negócio da configuração C2 necessária para responder corretamente, quando houver.
`observacao`	Anotações sobre ambiguidades ou decisões de interpretação.

Fonte: Elaborado pelo autor.

- **DuckDB:** conforme Raasveldt e Mühleisen (2019), é um sistema de gerenciamento de banco de dados analítico executado embarcado no próprio processo da aplicação, sem servidor separado. A leitura direta de arquivos CSV e o foco em consultas analíticas o tornam adequado para montar o banco a partir dos arquivos anexados.
- **Python e FastAPI:** linguagem e *framework* do *backend*, escolhidos pela disponibilidade de bibliotecas para acesso ao DuckDB, à API da OpenAI e à análise de dados do experimento (FASTAPI, 2026).
- **Vue.js:** *framework* do *frontend*, utilizado para construir a interface de anexação, cadastro de contexto e conversa (VUE.JS, 2026).
- **Apache ECharts:** biblioteca de visualização para a *web* baseada em especificações declarativas (LI et al., 2018). A configuração de cada gráfico é um objeto JSON, o que facilita gerá-la a partir da sugestão do modelo.
- **API da OpenAI:** acesso ao modelo de linguagem descrito na Seção 3.7.

4 Metodologia

Este capítulo descreve como a pergunta de pesquisa será respondida. São apresentados a classificação da pesquisa, as etapas do trabalho, o objetivo de medição, os sujeitos, materiais e procedimentos de coleta, a construção do banco de perguntas, o desenho do experimento de acurácia e do estudo com usuários, a análise dos dados, o processo de desenvolvimento do software, as ameaças à validade e o cronograma. O assistente avaliado e suas configurações de contexto foram descritos no Capítulo 3.

4.1 Classificação da pesquisa

Quanto à natureza, a pesquisa é aplicada, pois busca gerar conhecimento para a solução de um problema prático: a obtenção de respostas confiáveis a perguntas de negócio por usuários não técnicos. Quanto à abordagem, é predominantemente quantitativa, com um componente qualitativo no estudo com usuários. Quanto aos objetivos, é explicativa, porque procura estabelecer o efeito de uma variável, o nível de contexto de negócio, sobre a acurácia das respostas. Quanto aos procedimentos, é experimental: uma variável é manipulada de forma controlada, enquanto as demais são mantidas constantes, e o efeito sobre as variáveis dependentes é medido (WOHLIN et al., 2012).

4.2 Etapas do trabalho

O trabalho será conduzido em oito etapas, apresentadas na Tab. 8 com a saída de cada uma e a fase em que será realizada. As etapas 1 e 2 compõem o TCC1, e as etapas 4 a 8, o TCC2. A etapa 3 começa no TCC1 e termina no início do TCC2.

4.3 Objetivo de medição

A ligação entre a pergunta de pesquisa e as métricas coletadas será organizada pela abordagem *Goal Question Metric* (GQM), na qual um objetivo de medição é refinado em perguntas, e cada pergunta é respondida por métricas definidas (SOLINGEN et al., 2002). O objetivo de medição é analisar o assistente *text-to-SQL* com o propósito de avaliar o efeito do contexto de negócio, com respeito à acurácia das respostas e à autonomia do usuário, do ponto de vista do usuário não técnico, no contexto do domínio comercial. As perguntas e métricas derivadas desse objetivo estão na Tab. 9.

As perguntas Q1 a Q4 serão respondidas pelo experimento de acurácia, e a pergunta Q5, pelo estudo com usuários. O capítulo de resultados, no TCC2, seguirá essa

Tabela 8 – Etapas do trabalho

Nº	**Etapa**	**Saída**	**Fase**
1	Revisão da literatura	Referencial teórico	TCC1
2	Proposta da solução	Requisitos, arquitetura e configurações de contexto	TCC1
3	Definição das tabelas do domínio comercial	Arquivos CSV, anonimizados quando necessário	TCC1/TCC2
4	Construção do banco de perguntas	20 perguntas com gabarito, congeladas	TCC2
5	Implementação do assistente	Assistente funcional nas três configurações	TCC2
6	Experimento de acurácia	Registros de execução e acurácia por configuração	TCC2
7	Estudo com usuários	Acerto, tempo, escore SUS e observações	TCC2
8	Análise e escrita	Resultados, discussão e conclusão	TCC2

Fonte: Elaborado pelo autor.

Tabela 9 – Perguntas e métricas derivadas do objetivo de medição

ID	**Pergunta**	**Métrica**
Q1	O nível de contexto altera a acurácia das respostas?	Acurácia de execução por configuração
Q2	Em que tipo de pergunta o contexto mais contribui?	Acurácia de execução por estrato e configuração
Q3	Que erros o contexto elimina e quais persistem?	Distribuição dos erros por categoria e configuração
Q4	As respostas são estáveis entre execuções?	Consistência entre repetições
Q5	Usuários não técnicos obtêm respostas corretas sem apoio?	Taxa de acerto das tarefas, tempo por tarefa e escore SUS

Fonte: Elaborado pelo autor.

mesma organização.

4.4 Sujeitos, materiais e procedimentos de coleta

4.4.1 Sujeitos e objeto da pesquisa

O objeto do experimento de acurácia será o banco de 20 perguntas de negócio descrito na Seção 4.5. Participarão da pesquisa dois grupos de pessoas, todos da empresa que fornecerá as tabelas do domínio comercial: (i) analistas da área de negócio, que validarão

as perguntas e os gabaritos; e (ii) de 5 a 8 profissionais não técnicos do domínio comercial, isto é, que não escrevem consultas SQL, que participarão do estudo com usuários.

4.4.2 Materiais e equipamentos

Serão utilizados:

- as tabelas do domínio comercial, em formato CSV, anonimizadas quando necessário;
- o assistente desenvolvido, conforme o Capítulo 3;
- o modelo GPT-5.6 Terra, acessado pela API da OpenAI em uma versão datada fixa (OPENAI, 2026b);
- o banco de dados DuckDB (RAASVELDT; MÜHLEISEN, 2019);
- o questionário *System Usability Scale* (SUS) (BROOKE, 1996);
- o Termo de Consentimento Livre e Esclarecido (TCLE), apresentado em apêndice;
- um computador com o assistente instalado, usado em todas as sessões do estudo com usuários.

4.4.3 Procedimentos de coleta de dados

No experimento de acurácia, os dados serão coletados automaticamente pelo componente de registro do assistente, que gravará, para cada execução, a pergunta, a configuração, a repetição, o *prompt*, a consulta gerada, o resultado, o tempo e o custo. No estudo com usuários, serão registrados, para cada tarefa, se o participante chegou à resposta correta e o tempo gasto, além das respostas ao questionário SUS e das anotações feitas pelo pesquisador durante a sessão e a entrevista.

4.5 Banco de perguntas e gabarito

As perguntas serão redigidas como um usuário não técnico as faria e distribuídas em quatro estratos de dificuldade, com cinco perguntas cada: perguntas simples, perguntas que exigem junção de tabelas, perguntas que dependem de uma regra de negócio e perguntas ambíguas. Para cada pergunta, o autor escreverá uma consulta SQL de referência, cuja execução no DuckDB produzirá o resultado esperado, seguindo o formato de item apresentado na Seção 3.9.

Os analistas da área de negócio avaliarão se cada pergunta é realista e se o gabarito reflete a regra de negócio vigente. As divergências serão resolvidas e registradas antes do congelamento. O banco será congelado e versionado antes da primeira execução do

experimento, para evitar que perguntas ou gabaritos sejam ajustados depois de conhecido o desempenho do modelo.

4.6 Experimento de acurácia

4.6.1 Variáveis

A variável independente será a configuração de contexto de negócio, com três níveis (C0, C1 e C2), definidos na Seção 3.5. As variáveis dependentes serão o acerto de cada resposta, a categoria do erro, quando houver, e a validade sintática da consulta gerada. Serão mantidos constantes o modelo e sua versão, a temperatura (zero), as instruções gerais do *prompt*, as tabelas, o banco de perguntas e a ausência de autocorreção.

4.6.2 Procedimento

Cada pergunta será executada em cada uma das três configurações, com três repetições, o que totaliza 180 execuções de geração. As execuções serão feitas pelo *harness* do experimento, sem intervenção manual, e todas serão registradas. Como as mesmas perguntas serão submetidas às três configurações, o desenho é pareado: cada pergunta funciona como seu próprio controle.

4.6.3 Regra de acerto

A métrica principal será a acurácia de execução, que considera correta a resposta cuja consulta, ao ser executada, produz o mesmo resultado da consulta de referência (LI et al., 2023). Essa métrica foi escolhida porque avalia o resultado que o usuário de fato recebe, e não a forma da consulta: duas consultas escritas de modo diferente podem ser igualmente corretas.

O resultado da consulta gerada será considerado equivalente ao do gabarito quando: (i) contiver o mesmo conjunto de linhas, desconsiderando a ordem, exceto quando a pergunta pedir ordenação; (ii) desconsiderar nomes e ordem das colunas; e (iii) apresentar diferenças numéricas de no máximo 0,01, para acomodar arredondamentos. Os casos limítrofes serão decididos manualmente e registrados com a justificativa.

Para cada pergunta e configuração, o acerto será definido pela maioria das três repetições. A consistência, isto é, a proporção de perguntas em que as três repetições produzem o mesmo veredito, será medida separadamente (Q4).

4.6.4 Classificação dos erros

Cada resposta incorreta receberá uma categoria principal de erro: esquema (tabela ou coluna errada ou inexistente); junção; filtro ou regra de negócio; agregação ou agrupamento; data ou período; interpretação da pergunta; ou consulta inválida, quando a consulta não puder ser executada. A distribuição dessas categorias entre as configurações mostrará quais erros o contexto de negócio elimina e quais persistem (Q3).

4.7 Estudo com usuários

O estudo avaliará se usuários não técnicos conseguem obter respostas corretas com o assistente sem apoio de um analista. Ele será realizado apenas na configuração de melhor desempenho no experimento de acurácia, com 5 a 8 participantes. Estudos de usabilidade com poucos participantes são capazes de revelar a maior parte dos problemas de uma interface (NIELSEN; LANDAUER, 1993), mas não permitem generalização estatística; por isso, os resultados serão tratados como indicativos.

Cada sessão seguirá o mesmo roteiro: (i) leitura e assinatura do TCLE; (ii) apresentação breve do assistente, sem qualquer instrução sobre SQL; (iii) execução de 4 a 6 tarefas, cada uma pedindo uma informação de negócio cuja resposta é conhecida; (iv) preenchimento do questionário SUS; e (v) entrevista curta sobre a experiência. Durante as tarefas, o pesquisador observará se o texto interpretativo e o gráfico ajudaram ou confundiram o participante e se houve casos em que o texto contradisse os números exibidos.

As métricas serão a taxa de acerto das tarefas, o tempo por tarefa e o escore SUS, que varia de 0 a 100 (BROOKE, 1996). O roteiro, as tarefas e a regra de acerto serão descritos de forma independente da empresa, de modo que o estudo possa ser replicado em outras organizações.

Os participantes serão identificados apenas por códigos, e os dados coletados serão usados exclusivamente para este trabalho. Caso o prazo não comporte o estudo completo, ele será reduzido a uma avaliação qualitativa com três participantes, sem prejuízo do experimento de acurácia, que sustenta a conclusão principal.

4.8 Análise dos dados

No experimento de acurácia, será calculada a acurácia de cada configuração, com intervalo de confiança de 95%. Como o desfecho de cada pergunta é binário (acerto ou erro) e as mesmas perguntas são avaliadas nas três configurações, a diferença entre elas será testada pelo teste Q de Cochran (COCHRAN, 1950). Havendo diferença significativa, as configurações serão comparadas duas a duas pelo teste de McNemar (MCNEMAR, 1947), com correção de Bonferroni para comparações múltiplas. Também serão apresentadas

a acurácia por estrato (Q2), a distribuição dos erros por categoria (Q3) e a consistência entre repetições (Q4). Com 20 perguntas, o poder estatístico é limitado e apenas diferenças grandes entre as configurações poderão ser detectadas; por isso, além dos valores-p, serão reportados os intervalos de confiança e o tamanho das diferenças, e os resultados serão tratados como indicativos.

No estudo com usuários, serão calculadas estatísticas descritivas da taxa de acerto, do tempo por tarefa e do escore SUS, e as observações e entrevistas serão analisadas qualitativamente. A análise será feita em Python, com bibliotecas de manipulação de dados e de estatística.

4.9 Processo de desenvolvimento do software

O assistente será desenvolvido com o método Kanban, utilizando um quadro no GitHub Projects com as colunas *Backlog*, A fazer, Em andamento, Revisão e Concluído. Cada cartão do quadro corresponderá a um requisito da Tab. 5 ou a uma parte do cronograma de esforço (Tab. 11), o que permitirá rastrear cada entrega até o requisito que a motivou. O trabalho em andamento será limitado a dois itens simultâneos. O código, o banco de perguntas e os registros do experimento serão versionados no mesmo repositório, para permitir a reprodução dos resultados.

4.10 Ameaças à validade

As ameaças à validade estão organizadas na Tab. 10 segundo os quatro tipos usuais em experimentos de engenharia de software: interna, de construto, externa e de conclusão (WOHLIN et al., 2012).

4.11 Cronograma

O calendário do TCC2 ainda não foi divulgado. Por isso, o planejamento usa semanas relativas, de S1 (primeira semana do TCC2) a S16, considerando um semestre de 16 semanas; as datas serão definidas quando o calendário for publicado.

A Tab. 11 apresenta o esforço estimado para cada parte do desenvolvimento do assistente, e a Tab. 12, o esforço das atividades de pesquisa e escrita.

O esforço total estimado é de cerca de 280 horas, o que corresponde a aproximadamente 17,5 horas por semana ao longo de 16 semanas. Se a disponibilidade for menor, serão reduzidas primeiro a parte D7, com gráficos mais simples, e a atividade P4, com a versão reduzida do estudo com usuários.

Tabela 10 – Ameaças à validade e mitigações

Tipo	**Ameaça**	**Mitigação**
Interna	Perguntas escritas pelo autor, que conhece as regras de negócio	Congelamento prévio do banco e validação por analistas de negócio
Interna	Não determinismo do modelo	Temperatura zero, versão fixa, três repetições e medida de consistência
Construto	Consulta incorreta que coincide com o resultado esperado	Revisão manual de uma amostra dos acertos
Construto	Descrições e regras de C1 e C2 escritas pelo autor, possivelmente melhores que as de um usuário real	Descrições de tamanho e estilo realistas; registro como limitação
Externa	Um modelo, um domínio e uma base de dados	Declaração explícita do escopo; ausência de generalização além dele
Externa	Poucos participantes no estudo com usuários	Tratamento dos resultados como indicativos
Conclusão	Apenas 20 perguntas limitam o poder estatístico	Intervalos de confiança e tamanho das diferenças, além dos valores-p

Fonte: Elaborado pelo autor.

A Tab. 13 apresenta a sequência das atividades. O banco de perguntas será construído em paralelo ao desenvolvimento, e a escrita começará durante o experimento.

Os marcos do TCC2 serão: o congelamento do banco de perguntas ao fim de S6; o assistente pronto nas três configurações ao fim de S8; a escolha da melhor configuração ao fim de S11; a conclusão do estudo com usuários ao fim de S13; e a entrega em S16. Como o estudo com usuários pode ser reduzido sem afetar o marco de S11, que sustenta a conclusão principal, ele funciona como folga do cronograma.

Tabela 11 – Esforço estimado por parte do desenvolvimento

ID	Parte	Requisitos	Esforço [h]
D1	Configuração do repositório, do *backend*, do *frontend* e do quadro Kanban	–	10
D2	Ingestão de CSV e metadados	RF01	12
D3	Repositório de contexto e telas de descrições e regras	RF02, RF03	18
D4	Construtor de contexto (C0, C1, C2)	RF06	12
D5	Cliente do modelo (geração e interpretação)	RF04, RF08	18
D6	Validador de SQL e executor	RNF01, RNF04	8
D7	Visualização com gráficos interativos	RF09	24
D8	Interface de conversa e modo avançado	RF04, RF05, RNF05	18
D9	Registro das execuções	RNF02, RNF03	6
D10	*Harness* do experimento e comparação com o gabarito	RF07	18
D11	Testes, correções e estabilização	Todos	20
	Total		**164**

Fonte: Elaborado pelo autor.

Tabela 12 – Esforço estimado das atividades de pesquisa e escrita

ID	Atividade	Esforço [h]
P1	Banco de perguntas, gabarito e validação com analistas	24
P2	Execução do experimento e classificação dos erros	16
P3	Análise estatística do experimento	10
P4	Estudo com usuários (preparação, TCLE, sessões e SUS)	20
P5	Análise do estudo com usuários	6
P6	Escrita do TCC2	40
	Total	**116**

Fonte: Elaborado pelo autor.

Tabela 13 – Sequência das atividades do TCC2 em semanas relativas

Atividade	**Semanas**	**IDs**
Configuração e ingestão de dados	S1–S2	D1, D2
Contexto de negócio	S2–S3	D3, D4
Modelo, validação e registro	S3–S5	D5, D6, D9
Interface de conversa	S4–S6	D8
Visualização	S6–S7	D7
Harness e testes	S7–S8	D10, D11
Banco de perguntas (em paralelo)	S1–S6	P1
Experimento de acurácia e análise	S9–S11	P2, P3
Estudo com usuários e análise	S12–S13	P4, P5
Escrita	S10–S16	P6

Fonte: Elaborado pelo autor.

5 Considerações finais

Este capítulo encerra a etapa de proposta do trabalho. São retomados o problema e o que foi produzido nesta etapa, apresentado o encaminhamento de cada objetivo específico, registradas as limitações e os riscos já conhecidos e listados os próximos passos.

5.1 Síntese do trabalho

Assistentes baseados em modelos de linguagem prometem permitir que usuários não técnicos consultem bancos de dados empresariais em linguagem natural. Em bases reais, porém, o significado das métricas depende de regras de negócio ausentes do esquema, e uma consulta válida pode retornar um número incorreto sem que o usuário perceba. O trabalho se propõe a medir em que medida o contexto de negócio fornecido ao modelo reduz esse problema e se, com ele, usuários não técnicos obtêm respostas corretas sem apoio.

Nesta etapa, o Capítulo 2 reuniu os fundamentos necessários, incluindo a formulação da tarefa, a métrica de acurácia de execução e a análise dos trabalhos relevantes, que mostrou a ausência de avaliações em bancos empresariais reais com contexto escrito pelo próprio usuário. O Capítulo 3 especificou o assistente: requisitos, arquitetura, montagem do contexto nas três configurações, escolha do modelo e formato do banco de perguntas. O Capítulo 4 definiu o experimento de acurácia, o estudo com usuários, a análise dos dados, as ameaças à validade e o cronograma do TCC2. Com isso, o trabalho chega ao fim do TCC1 com o problema delimitado, a solução especificada e a avaliação planejada.

5.2 Objetivos e encaminhamento

A Tabela 14 relaciona cada objetivo específico à forma como será atingido e ao marco do TCC2 em que deverá estar concluído, de acordo com o cronograma da Seção 4.11.

5.3 Limitações e riscos

O escopo do trabalho impõe limitações conhecidas desde o início: um único modelo de linguagem, um único domínio de negócio e uma única base de dados. Os resultados valerão para essas condições, e a extensão para outros modelos, domínios e empresas fica como trabalho futuro. Além dessas limitações, foram identificados riscos de execução, apresentados na Tab. 15 com as respectivas mitigações. Os riscos à validade dos resultados foram tratados na Seção 4.10.

Tabela 14 – Encaminhamento dos objetivos específicos no TCC2

Objetivo específico	**Como será atingido**	**Marco**
Construir o banco de perguntas com gabarito	Redação das perguntas, validação pelos analistas de negócio e congelamento	Fim de S6
Desenvolver o assistente nas três configurações	Implementação conforme o Capítulo 3	Fim de S8
Medir a acurácia e classificar os erros	Experimento de acurácia e análise estatística	Fim de S11
Avaliar a autonomia de usuários não técnicos	Estudo com usuários na configuração de melhor desempenho	Fim de S13

Fonte: Elaborado pelo autor.

Tabela 15 – Riscos de execução e mitigações

Risco	**Mitigação**
Tabelas do domínio comercial ainda não definidas	Definição no início do TCC2, antes da construção do banco de perguntas
Autorização de uso e presença de dados pessoais	Autorização formal da empresa e anonimização antes da ingestão
Dificuldade de recrutar participantes	Versão reduzida do estudo, com avaliação qualitativa de três participantes
Alteração ou descontinuação do modelo na API	Uso de versão datada fixa e registro da versão utilizada
Custo da API acima do previsto	Estimativa de custo antes do experimento e redução de repetições, se necessário
Esforço maior que a disponibilidade de horas	Simplificação dos gráficos e versão reduzida do estudo com usuários

Fonte: Elaborado pelo autor.

5.4 Próximos passos

O início do TCC2 depende de quatro definições: as tabelas do domínio comercial, com a autorização de uso; a versão datada do modelo que será fixada no experimento; a estimativa de custo das execuções; e o calendário da disciplina, que permitirá converter as semanas relativas do cronograma em datas.

Resolvidas essas pendências, o desenvolvimento do assistente e a construção do banco de perguntas ocorrerão em paralelo. Os marcos previstos são o congelamento do banco de perguntas ao fim da sexta semana, o assistente pronto nas três configurações ao fim da oitava, a escolha da melhor configuração ao fim da décima primeira, a conclusão do estudo com usuários ao fim da décima terceira e a entrega na décima sexta semana. Ao final, o trabalho deverá responder à pergunta de pesquisa com dados: qual a acurácia do

assistente sem contexto e com cada nível de contexto de negócio e se, na melhor condição, usuários não técnicos conseguem obter respostas corretas sem apoio.

Referências

ALPAR, P.; SCHULZ, M. Self-service business intelligence. *Business & Information Systems Engineering*, v. 58, n. 2, p. 151–155, 2016. Citado 2 vezes nas páginas 23 e 27.

BANGOR, A.; KORTUM, P. T.; MILLER, J. T. An empirical evaluation of the system usability scale. *International Journal of Human-Computer Interaction*, v. 24, n. 6, p. 574–594, 2008. Citado na página 32.

BEVAN, N.; CARTER, J.; HARKER, S. ISO 9241-11 revised: What have we learnt about usability since 1998? In: *Human-Computer Interaction: Design and Evaluation*. [S.l.]: Springer, 2015, (Lecture Notes in Computer Science). p. 143–151. Citado na página 32.

BRASIL. *Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD)*. 2018. Diário Oficial da União. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm>. Acesso em: 20 out. 2026. Citado na página 42.

BROOKE, J. SUS: A "quick and dirty" usability scale. In: JORDAN, P. W. et al. (Ed.). *Usability Evaluation In Industry*. [S.l.]: CRC Press, 1996. p. 207–212. Citado 3 vezes nas páginas 32, 47 e 49.

BROWN, T. et al. Language models are few-shot learners. In: *Advances in Neural Information Processing Systems*. Curran Associates, Inc., 2020. v. 33, p. 1877–1901. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2020/file/1457c0d6bfcb4967418bfb8ac142f64a-Paper.pdf>. Citado 2 vezes nas páginas 23 e 27.

COCHRAN, W. G. The comparison of percentages in matched samples. *Biometrika*, v. 37, n. 3-4, p. 256–266, 1950. Citado na página 49.

FASTAPI. *FastAPI: documentação oficial*. 2026. Disponível em: <https://fastapi.tiangolo.com/>. Acesso em: 20 out. 2026. Citado na página 43.

GAO, D. et al. Text-to-SQL empowered by large language models: A benchmark evaluation. *Proceedings of the VLDB Endowment*, v. 17, n. 5, p. 1132–1145, 2024. Citado 4 vezes nas páginas 28, 32, 33 e 40.

HONG, Z. et al. Knowledge-to-SQL: Enhancing SQL generation with data expert LLM. In: *Findings of the Association for Computational Linguistics: ACL 2024*. [S.l.]: Association for Computational Linguistics, 2024. p. 10997–11008. Citado 4 vezes nas páginas 29, 30, 32 e 33.

HONG, Z. et al. Next-generation database interfaces: A survey of LLM-based text-to-SQL. *IEEE Transactions on Knowledge and Data Engineering*, v. 37, n. 12, p. 7328–7345, 2025. Citado 2 vezes nas páginas 23 e 28.

JI, Z. et al. Survey of hallucination in natural language generation. *ACM Computing Surveys*, v. 55, n. 12, p. 1–38, 2023. Citado 3 vezes nas páginas 24, 31 e 38.

KATSOGIANNIS-MEIMARAKIS, G.; KOUTRIKA, G. A survey on deep learning approaches for text-to-SQL. *The VLDB Journal*, v. 32, n. 4, p. 905–936, 2023. Citado 2 vezes nas páginas 23 e 28.

KIMBALL, R.; ROSS, M. *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. [S.l.]: Wiley, 2013. ISBN 9781118530801. Citado na página 30.

LENNERHOLT, C.; LAERE, J. van; SÖDERSTRÖM, E. Implementation challenges of self service business intelligence: A literature review. In: *Proceedings of the 51st Hawaii International Conference on System Sciences*. [S.l.]: Hawaii International Conference on System Sciences, 2018. Citado na página 27.

LEWIS, J. R. The system usability scale: Past, present, and future. *International Journal of Human-Computer Interaction*, v. 34, n. 7, p. 577–590, 2018. Citado na página 32.

LI, D. et al. ECharts: A declarative framework for rapid construction of web-based visualization. *Visual Informatics*, v. 2, n. 2, p. 136–146, 2018. Citado na página 43.

LI, J. et al. Can LLM already serve as a database interface? A BIg bench for large-scale database grounded text-to-SQLs. In: *Advances in Neural Information Processing Systems*. [S.l.]: Curran Associates, Inc., 2023. v. 36, p. 42330–42357. Citado 8 vezes nas páginas 23, 29, 30, 32, 33, 40, 42 e 48.

MCNEMAR, Q. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, v. 12, n. 2, p. 153–157, 1947. Citado na página 49.

NIELSEN, J.; LANDAUER, T. K. A mathematical model of the finding of usability problems. In: *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*. [S.l.]: ACM Press, 1993. (CHI '93), p. 206–213. Citado 2 vezes nas páginas 32 e 49.

OPENAI. *Data controls in the OpenAI platform*. 2026. OpenAI API Documentation. Disponível em: <https://platform.openai.com/docs/guides/your-data>. Acesso em: 20 out. 2026. Citado na página 42.

OPENAI. *GPT-5.6 Terra Model*. 2026. OpenAI API Documentation. Disponível em: <https://platform.openai.com/docs/models/gpt-5.6-terra>. Acesso em: 20 out. 2026. Citado 3 vezes nas páginas 41, 42 e 47.

OPENAI. *Structured model outputs*. 2026. OpenAI API Documentation. Disponível em: <https://platform.openai.com/docs/guides/structured-outputs>. Acesso em: 20 out. 2026. Citado 2 vezes nas páginas 28 e 41.

POURREZA, M.; RAFIEI, D. DIN-SQL: Decomposed in-context learning of text-to-SQL with self-correction. In: *Advances in Neural Information Processing Systems*. [S.l.]: Curran Associates, Inc., 2023. v. 36, p. 36339–36348. Citado 4 vezes nas páginas 29, 32, 33 e 38.

RAASVELDT, M.; MÜHLEISEN, H. DuckDB: an embeddable analytical database. In: *Proceedings of the 2019 International Conference on Management of Data*. [S.l.]: ACM, 2019. (SIGMOD '19), p. 1981–1984. Citado 2 vezes nas páginas 42 e 47.

SOLINGEN, R. van et al. Goal question metric (GQM) approach. In: *Encyclopedia of Software Engineering*. [S.l.]: John Wiley & Sons, 2002. Citado na página 45.

VASWANI, A. et al. Attention is all you need. In: *Advances in Neural Information Processing Systems*. Curran Associates, Inc., 2017. v. 30. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2017/file/3f5ee243547dee91fbd053c1c4a845aa-Paper.pdf>. Citado na página 27.

VUE.JS. *Introduction*. 2026. Vue.js Guide. Disponível em: <https://vuejs.org/guide/introduction.html>. Acesso em: 20 out. 2026. Citado na página 43.

WOHLIN, C. et al. *Experimentation in Software Engineering*. Berlin, Heidelberg: Springer, 2012. ISBN 9783642290442. Citado 2 vezes nas páginas 45 e 50.

YU, T. et al. Spider: A large-scale human-labeled dataset for complex and cross-domain semantic parsing and text-to-SQL task. In: *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*. [S.l.]: Association for Computational Linguistics, 2018. p. 3911–3921. Citado 4 vezes nas páginas 23, 29, 32 e 42.